Classificação de resíduos com redes neurais: arquitetura, desequilíbrio e resolução no TrashNet

JOÃO VICTOR OLIVEIRA GOMES - matrícula 9999999
DANILLO CASTRO DE SOUSA - matrícula 9999999
PEDRO HENRIQUE CÂMARA MATOS - matrícula 9999999
LETÍCIA MONTEIRO VIDAL - matrícula 9999999
FRANCISCO VITOR RODRIGUES XAVIER - matrícula 9999999

Atividade final - Redes Neurais Artificiais

Repositório GitHub: publicação pendente; inserir o endereço público antes da submissão.

Versão para revisão da equipe. Matrículas provisórias informadas pelos autores.

Resumo

Este estudo compara MLP e CNN na classificação de 2.527 imagens do TrashNet, preservando seis classes. Foram realizados seis experimentos controlados com pesos de classe e três resoluções. A divisão estratificada foi corrigida para agrupar três pares de imagens idênticas com rótulos conflitantes. A CNN em 128 × 96 com pesos de classe, selecionada exclusivamente pelo F1 macro de validação, obteve 58,16% de acurácia e 0,5718 de F1 macro no teste. A análise relaciona desempenho, desequilíbrio, custo e limitações de generalização.

Palavras-chave: redes neurais; classificação de resíduos; TrashNet; desequilíbrio de classes.

1 Introdução

A classificação visual de resíduos pode apoiar a triagem, mas materiais distintos compartilham formas, cores e embalagens. O TrashNet oferece um cenário inicial para estudar esse problema (Thung; Yang, 2016). O objetivo é comparar uma rede totalmente conectada (MLP) e uma rede convolucional (CNN), investigar o efeito de pesos na perda e avaliar se a maior resolução compensa seu custo computacional. O estudo mede classificação de imagens inteiras, sem localizar objetos.

2 Materiais e métodos

Foi usado apenas dataset-resized.zip. A inspeção confirmou 2.527 imagens RGB de 512 × 384 pixels e nenhuma imagem inválida; três arquivos auxiliares macOS foram ignorados. Mantiveram-se vidro (glass), papel (paper), papelão (cardboard), plástico (plastic), metal e outros resíduos (trash). SHA-256 do ZIP, hashes de bytes e pixels e o manifesto da divisão estão preservados no projeto.

2.1 Divisão, pré-processamento e controle

A semente 42 foi usada em duas divisões estratificadas (70/30 e 50/50 do restante): 1.768 imagens de treino, 379 de validação e 380 de teste. Três pares idênticos tinham rótulos conflitantes. Cada grupo foi ancorado na partição de sua primeira linha na ordenação fixa. Uma troca entre plastic332.jpg e plastic1.jpg preservou as contagens por classe; todos os pares ficaram no treino. Os rótulos originais foram mantidos, portanto permanece ruído de anotação.

As imagens foram orientadas por EXIF, convertidas para RGB e redimensionadas diretamente da referência por LANCZOS; tensores float32 em C × A × L foram divididos por 255. Não houve aumento de dados nem reamostragem. Essa decisão mantém o contraste entre pesos de classe isolado. A interpolação usa Pillow (Pillow Contributors, s.d.).

2.2 Arquiteturas e treinamento

Tabela 1 - Arquiteturas e quantidade de parâmetros treináveis.

Rede	Camadas	Parâmetros
MLP	36.864 entradas → 128 ReLU → dropout 0,2 → 64 ReLU → dropout 0,2 → 6 logits	4.727.366
CNN	Conv 3×3 com 16, 32 e 64 filtros; BatchNorm, ReLU e MaxPool 2×2 em cada bloco; GAP → 6 logits	24.086

Fonte: Elaboração a partir dos registros experimentais (2026).

Na CNN, a primeira convolução tem passo 2; as demais, passo 1; todas usam padding 1 e não usam bias. GAP reduz cada mapa à sua média espacial, conservando o número de parâmetros nas três resoluções. A MLP representa uma referência sem estrutura espacial explícita; a CNN compartilha filtros locais. As redes foram implementadas em PyTorch (PyTorch Contributors, s.d.).

Adotaram-se Adam (passos adaptativos), taxa comum 0,0001, lote 32 (viável em CPU nas três resoluções) e limite de 25 épocas. A entropia cruzada é apropriada às seis classes mutuamente exclusivas e recebe logits (PyTorch Contributors, s.d.). Sem pré-treinamento, cada rede reiniciou a semente 42 e a inicialização padrão do PyTorch; hashes confirmam pesos iniciais idênticos nos pares. Não houve weight decay ou agendador.

Nos treinos ponderados, $w_c = 1.768/(6n_c)$, usando apenas o treino: glass=0,842, paper=0,708, cardboard=1,045, plastic=0,874, metal=1,027, trash=3,069. A perda média divide a soma das perdas ponderadas pela soma dos pesos dos exemplos.

2.3 Busca exploratória e escolha dos modelos

Tabela 2 - Busca em 128 × 96 sem pesos; somente validação.

Taxa Adam	F1 val. MLP	F1 val. CNN	Média
0,001	0,1385	0,5078	0,3232
0,0003	0,3013	0,5356	0,4184
0,0001	0,3944	0,5337	0,4641

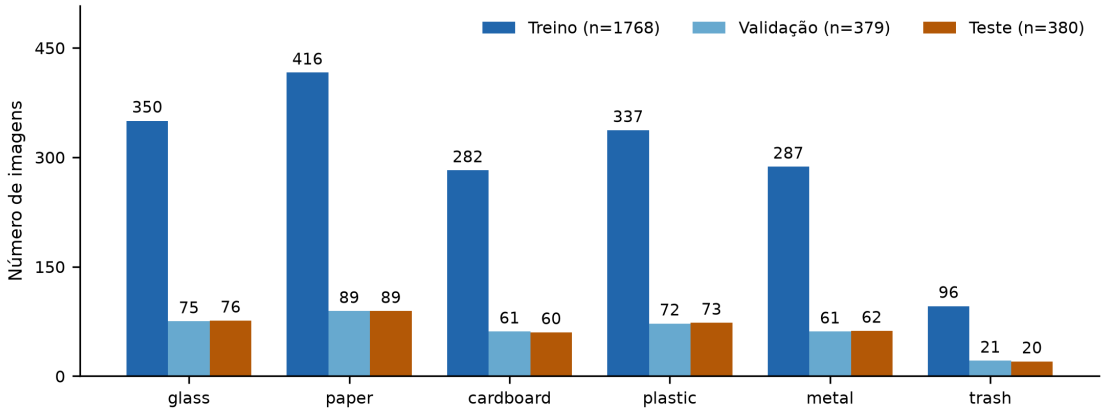
Fonte: Elaboração a partir dos registros experimentais (2026).

Após baixa aprendizagem na MLP inicial, três taxas foram comparadas pela média do F1 macro de validação das duas redes, nos checkpoints de menor perda; empates seguiriam a ordem da tabela. Os seis treinos finais foram reiniciados com a taxa escolhida. Early stopping (perda de validação, paciência 5, min_delta=0) limita custo e evita manter pesos após a deterioração da validação. Entre os seis checkpoints restaurados, o maior F1 macro de validação define o modelo principal; hashes e escolhas foram congelados antes do teste.

3 Resultados

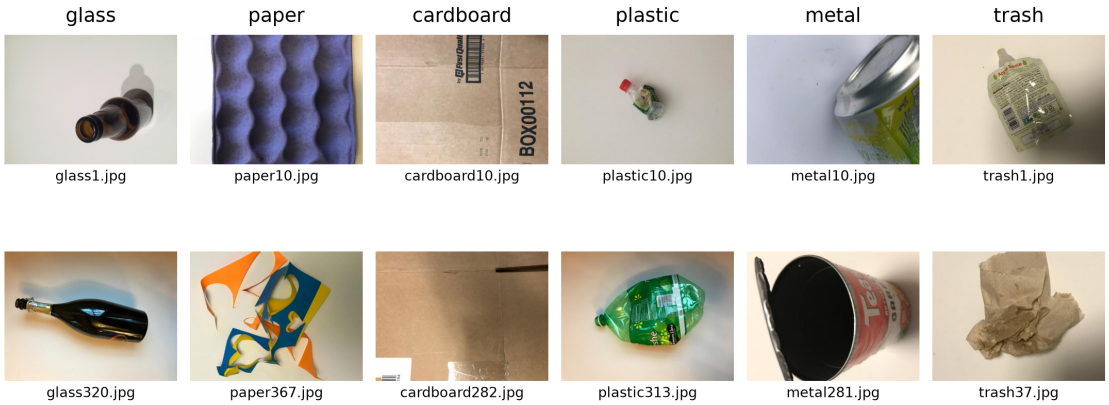
A Figura 1 confirma a estratificação. Trash representa 137/2.527 imagens (5,42%), contra 594 de paper; a razão entre a maior e a menor classe é 4,34. Arredondamentos inteiros explicam as pequenas diferenças em relação a 70/15/15.

Figura 1 - Distribuição das seis classes em treinamento, validação e teste.



Fonte: Elaboração a partir dos registros experimentais (2026).

Figura 2 - Dois exemplos de treinamento por classe, escolhidos por uma regra fixa.



Fonte: TrashNet (Thung; Yang, 2016), organizado neste estudo.

Vidro e plástico podem compartilhar o formato de garrafas; papel e papelão apresentam texturas semelhantes. Rótulos, amassados, reflexos, sombras e a classe heterogênea trash dificultam a discriminação visual (Figura 2).

Figura 3 - A mesma imagem de treino, plastic10.jpg, nas três resoluções.



Fonte: TrashNet (Thung; Yang, 2016); redimensionamento do estudo.

Na Figura 3, os painéis têm o mesmo tamanho físico para expor a perda de detalhe. Cada entrada foi gerada diretamente da referência, preservando a proporção 4:3.

3.1 Desempenho global e custo

Tabela 3 - Resultados dos seis checkpoints no mesmo teste (n=380); F1 sempre macro.

ID / experimento	F1 val.	Acurácia teste	F1 teste	Época salva
M1 - MLP 128×96 sem pesos	0,3944	44,47%	0,3583	25
M2 - MLP 128×96 com pesos	0,3716	38,42%	0,3304	25
M3 - CNN 128×96 sem pesos	0,5337	61,84%	0,5241	17
M4 - CNN 128×96 com pesos	0,5591	58,16%	0,5718	17
M5 - CNN 256×192 sem pesos	0,5511	59,21%	0,5131	23
M6 - CNN 512×384 sem pesos	0,5493	62,11%	0,5223	24

Fonte: Elaboração a partir dos registros experimentais (2026).

O maior F1 macro de validação foi o de M4 (0,5591), escolhido antes de consultar o teste. Seu F1 macro de teste foi 0,5718, com intervalo percentil de 95% [0,5243; 0,6181]. Acurácia e F1 macro são complementares: o segundo dá o mesmo peso às seis classes.

Tabela 4 - Custos medidos na etapa final, excluída a busca exploratória.

ID	Parâmetros	MiB modelo	Épocas	Total (s)	s/época	RSS (MiB)
M1	4.727.366	18,037	25	56,7	2,27	661,2
M2	4.727.366	18,037	25	60,4	2,42	662,9
M3	24.086	0,100	22	49,2	2,24	596,1
M4	24.086	0,100	22	50,9	2,31	594,2
M5	24.086	0,100	25	216,5	8,66	1015,5
M6	24.086	0,100	25	1258,6	50,34	2371,8

Fonte: Elaboração a partir dos registros experimentais (2026).

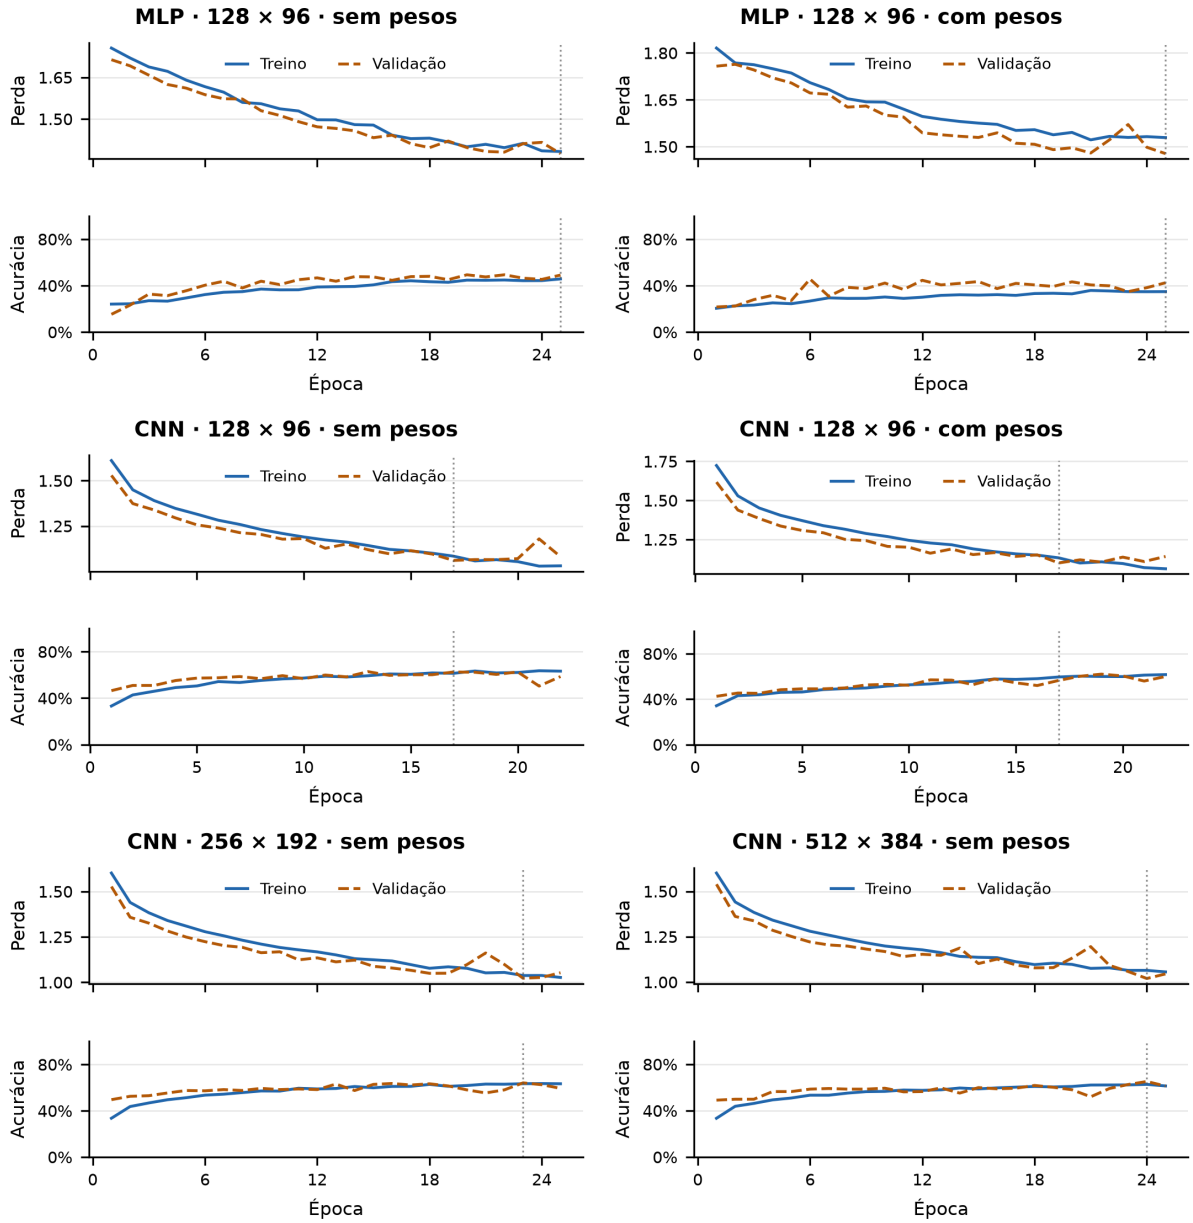
Hardware: Intel Core i3-1125G4, quatro núcleos físicos, oito lógicos e 14,8 GiB de RAM total. Foram usados CPU, quatro threads, PyTorch 2.14.1+cpu, Python 3.12.14 e lote 32 em todos os casos. Não houve redução de lote nas resoluções maiores.

O cronômetro perf_counter incluiu treino, validação por época e checkpoints; excluiu download, preparação dos caches, inicialização e avaliação final. A média é tempo total/épocas concluídas. RSS é o pico absoluto do processo, amostrado a cada 50 ms por psutil (Rodola, s.d.), incluindo páginas do cache mapeadas; não é a memória de toda a máquina. Não houve GPU. O tamanho em MiB considera model.pt, apenas pesos e buffers, não o estado do otimizador.

Os tempos são medições de uma execução em computador de uso geral e podem variar com carga de fundo, cache e temperatura. Os intervalos de desempenho usam 2.000 reamostragens estratificadas do teste, semente 20261127. Expressam incerteza amostral condicionada aos modelos, sem incluir variação entre sementes de treino ou mudança de domínio.

3.2 Curvas de aprendizagem

Figura 4 - Perda e acurácia de treino e validação dos seis experimentos.



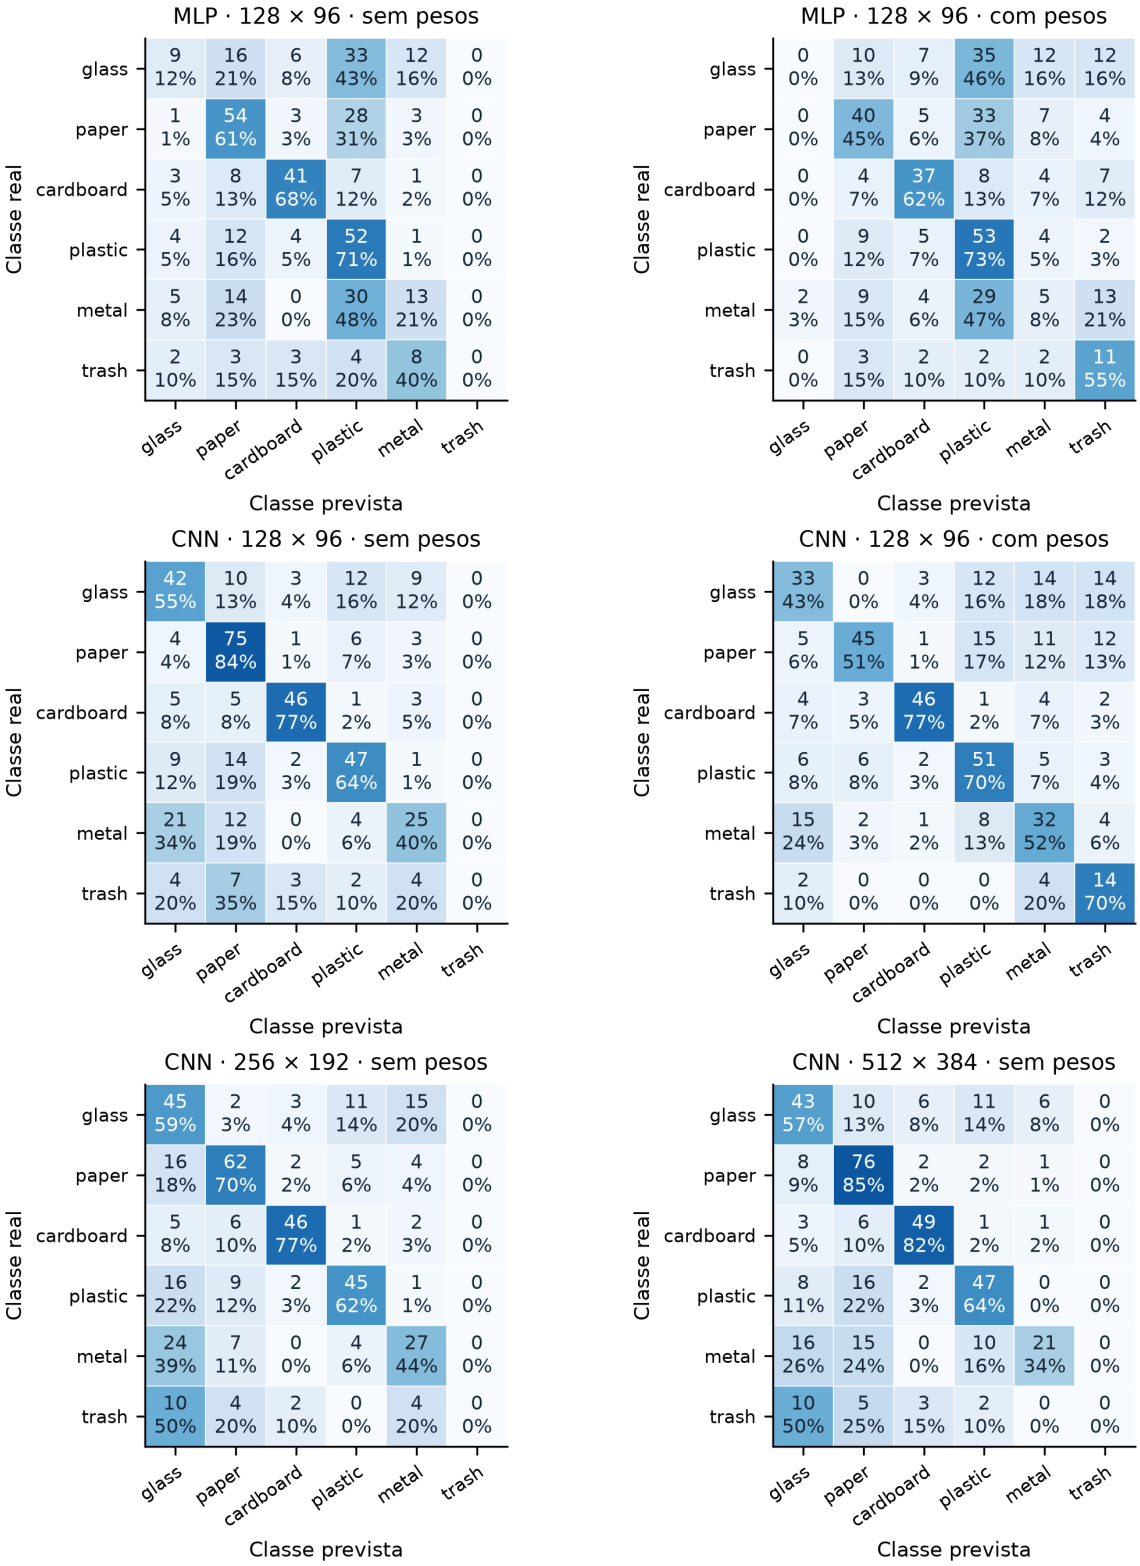
Fonte: Elaboração a partir dos registros experimentais (2026).

A linha vertical indica a época restaurada por menor perda de validação. O término da curva pode ocorrer depois dela, pois a paciência aguarda cinco épocas sem melhora. As métricas de treino foram agregadas durante atualizações, com dropout ativo na MLP; as de validação usam modo de avaliação. Portanto, validação acima de treino em alguns pontos não é, isoladamente, sinal de vazamento.

As MLPs completaram 25 épocas e salvaram a última: a perda de validação caiu de 1,714 para 1,375 sem pesos e de 1,758 para 1,478 com pesos. A redução até o limite não demonstra convergência nem sobreajuste persistente. Nas CNNs 128, ambas salvaram a época 17 e pararam na 22: o treino continuou melhorando sem nova mínima de validação. Na CNN ponderada, a acurácia de validação cresceu de 56,46% para 59,89% nesse intervalo, mas a perda piorou de 1,100 para 1,141. A divergência entre critérios ilustra por que recuperar a menor perda pode não recuperar a maior acurácia. As CNNs 256 e 512 completaram 25 épocas e restauraram, respectivamente, as épocas 23 e 24.

3.3 Matrizes de confusão

Figura 5 - Contagens e porcentagens por linha nos seis experimentos.



Fonte: Elaboração a partir dos registros experimentais (2026).

Linhas: classe real; colunas: classe prevista. Cada porcentagem divide a contagem pelo suporte da classe real; arredondamentos podem impedir soma exata de 100%. A ordem das classes é fixa em todos os painéis.

3.4 Métricas por classe

Tabela 5 - Precisão, recall, F1 e suporte de cada classe no teste.

Modelo	Classe	Precisão	Recall	F1	Suporte
M1	glass	0,375	0,118	0,180	76
	paper	0,505	0,607	0,551	89
	cardboard	0,719	0,683	0,701	60
	plastic	0,338	0,712	0,458	73
	metal	0,342	0,210	0,260	62
	trash	0,000	0,000	0,000	20
M2	glass	0,000	0,000	0,000	76
	paper	0,533	0,449	0,488	89
	cardboard	0,617	0,617	0,617	60
	plastic	0,331	0,726	0,455	73
	metal	0,147	0,081	0,104	62
	trash	0,224	0,550	0,319	20
M3	glass	0,494	0,553	0,522	76
	paper	0,610	0,843	0,708	89
	cardboard	0,836	0,767	0,800	60
	plastic	0,653	0,644	0,648	73
	metal	0,556	0,403	0,467	62
	trash	0,000	0,000	0,000	20
M4	glass	0,508	0,434	0,468	76
	paper	0,804	0,506	0,621	89
	cardboard	0,868	0,767	0,814	60
	plastic	0,586	0,699	0,638	73
	metal	0,457	0,516	0,485	62
	trash	0,286	0,700	0,406	20
M5	glass	0,388	0,592	0,469	76
	paper	0,689	0,697	0,693	89
	cardboard	0,836	0,767	0,800	60
	plastic	0,682	0,616	0,647	73
	metal	0,509	0,435	0,470	62
	trash	0,000	0,000	0,000	20
M6	glass	0,489	0,566	0,524	76
	paper	0,594	0,854	0,700	89
	cardboard	0,790	0,817	0,803	60
	plastic	0,644	0,644	0,644	73
	metal	0,724	0,339	0,462	62
	trash	0,000	0,000	0,000	20

Fonte: Elaboração a partir dos registros experimentais (2026).

Suporte é o número de exemplos da classe avaliada. F1 macro é a média aritmética dos seis F1, calculados por 2TP/(2TP+FP+FN). Os rótulos 0 a 5 são sempre explícitos e zero_division=0 trata divisões indefinidas (Scikit-learn Developers, s.d.). Não houve previsão para M1: trash; M3: trash; M5: trash; M6: trash. A precisão indefinida dessas classes foi registrada como zero; isso não elimina seu peso no F1 macro.

4 Discussão

Em 128 × 96, a diferença CNN menos MLP no F1 macro de teste foi 0,1658 sem pesos e 0,2414 com pesos. Essas diferenças descrevem as arquiteturas e o orçamento adotados, sem estabelecer superioridade universal.

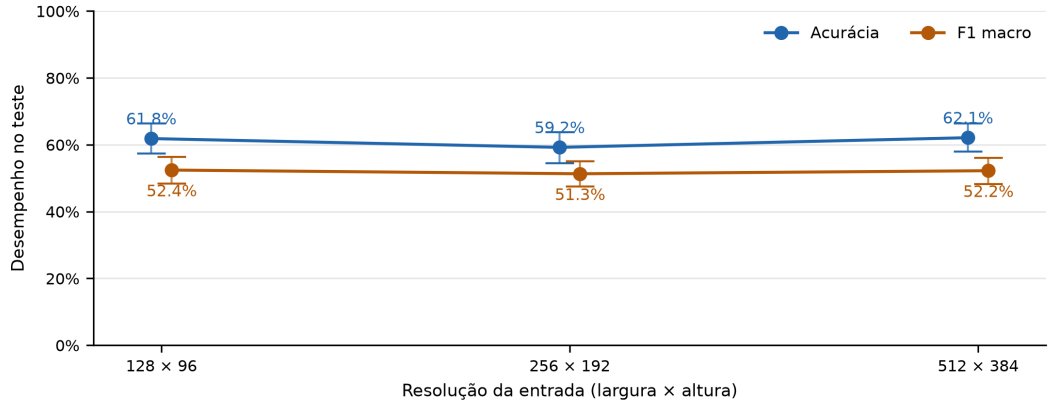
Tabela 6 - Efeito dos pesos: valor ponderado menos valor sem pesos.

Arquitetura	Δ F1 macro	Δ recall trash	Δ F1 trash
MLP	-0,0279	0,550	0,319
CNN	0,0477	0,700	0,406

Fonte: Elaboração a partir dos registros experimentais (2026).

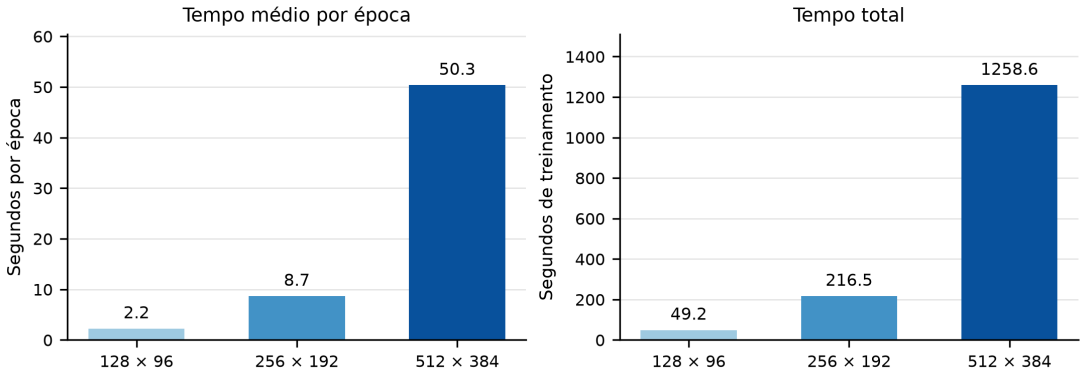
Na CNN, ponderar elevou o recall de trash de 0 para 70% (14/20), mas sua precisão foi 28,57%: 35 das 49 previsões trash eram de outras classes. O recall de paper caiu de 84,27% para 50,56%; a acurácia global caiu 3,68 pontos percentuais, enquanto F1 macro subiu 4,77 pontos. Na MLP, trash passou a ter 11 acertos, mas glass ficou sem acertos e o F1 macro caiu 2,79 pontos. O benefício depende da arquitetura e da classe.

Figura 6 - CNN sem pesos: desempenho no teste e intervalos bootstrap de 95%.



Fonte: Elaboração a partir dos registros experimentais (2026).

Figura 7 - CNN sem pesos: custo médio por época e tempo total.



Fonte: Elaboração a partir dos registros experimentais (2026).

Em 512 × 384 houve apenas um acerto adicional em 380 imagens: 236 contra 235 em 128 × 96. O F1 macro caiu de 0,5241 para 0,5223; 256 × 192 também não melhorou o teste. Com 16 vezes mais pixels e os mesmos 24.086 parâmetros, 512 × 384 custou 22,52 vezes mais por época, 25,59 vezes no total e 3,98 vezes em RSS. Neste protocolo, 128 × 96 ofereceu a melhor relação entre F1 e custo entre as CNNs sem pesos; aumentar a resolução não compensou.

4.1 Erros e limitações para aplicação

Figura 8 - Seis erros de M4, escolhido exclusivamente pela validação.



Fonte: Imagens do TrashNet (Thung; Yang, 2016); previsões do modelo selecionado.

O modelo selecionado errou 159 das 380 imagens de teste. O painel mostra até seis erros com maior probabilidade atribuída à classe prevista, com desempate pelo caminho do arquivo. Esse critério expõe erros de alta probabilidade, não uma amostra representativa de todos os erros. Softmax não equivale a confiança calibrada.

Em plastic364, o grande rótulo impresso ocupa parte da embalagem prevista como papel. Glass501 e glass499 são garrafas transparentes previstas como plástico. Cardboard33 apresenta superfície lisa e brilhante; metal37 mostra apenas parte de uma superfície curva refletiva: ambos foram previstos como plástico. Cardboard239, previsto como papel, exibe impressão colorida sobre a caixa. São hipóteses visuais de ambiguidade, sem prova de quais atributos a rede utilizou.

Na matriz de M4, paper → plastic e metal → glass somam 15 erros cada; glass → metal e glass → trash têm 14 cada. O painel de alta probabilidade não reproduz necessariamente essa frequência. Ruído nos rótulos de treino e semelhança entre embalagens limitam a interpretação, mesmo sem cópias exatas atravessando as partições.

O domínio é restrito: objetos geralmente isolados, fundos claros e pouca diversidade de cenários. Não houve avaliação externa com lixo misturado, oclusão, sujeira, múltiplos objetos ou novas câmeras. A classe trash agrega objetos distintos e a distribuição real pode diferir. Assim, os resultados não demonstram prontidão para uma esteira de triagem ou para decidir a reciclabilidade local de cada embalagem.

Há uma única semente e uma única divisão. Hashes não identificam todas as fotos diferentes do mesmo objeto; a independência por instância não é garantida. A busca exploratória também reutiliza a validação e pode se ajustar a ela. Repetições com sementes distintas, avaliação por objeto e um conjunto externo constituem próximos passos, sem reinterpretar o teste atual como validação.

4.2 Comparação com o estudo de referência

Yang e Thung (2016) reportaram 63% de acurácia com SVM e seis classes, usando 70/30 para treino/teste, e 22% com CNN após excluir trash, com cinco classes, entrada 256 × 256 e divisão 70/13/17. Aqui há seis classes, divisão 70/15/15 aproximada, outra arquitetura e treinamento. Esses valores são contexto histórico, não comparação controlada. Os aproximadamente 75% de CNN citados no README do TrashNet pertencem à continuação posterior dos experimentos (Thung; Yang, 2016).

5 Conclusão

O estudo executou os seis contrastes com divisão comum, inicializações controladas e teste reservado. As CNNs superaram as MLPs no F1 macro em ambos os pares de 128 × 96. A CNN ponderada, escolhida pela validação, atingiu F1 macro de teste 0,5718: recuperou trash, com perdas em outras classes. A ponderação prejudicou o F1 macro da MLP. Nas CNNs sem pesos, a maior resolução não compensou seu custo. Essas conclusões se restringem à divisão, semente e orçamento adotados. Repetições, aumento de dados, transferência de aprendizagem e avaliação externa são próximos passos. A extensão opcional YOLO não foi realizada.

Tabelas e figuras usam NumPy, pandas e Matplotlib (NumPy Developers, s.d.; Pandas Development Team, s.d.; Matplotlib Development Team, s.d.). Código, modelos, históricos e previsões acompanham o artigo. A elaboração recebeu assistência de IA; a conferência, compreensão e revisão pelos integrantes permanecem necessárias antes da submissão.

Referências

MATPLOTLIB DEVELOPMENT TEAM. **Matplotlib documentation**. [S. l.], [s. d.]. Disponível em: https://matplotlib.org/stable/. Acesso em: 16 out. 2026.

NUMPY DEVELOPERS. **NumPy documentation**. [S. l.], [s. d.]. Disponível em: https://numpy.org/doc/stable/. Acesso em: 16 out. 2026.

PANDAS DEVELOPMENT TEAM. **pandas documentation**. [S. l.], [s. d.]. Disponível em: https://pandas.pydata.org/docs/. Acesso em: 17 out. 2026.

PILLOW CONTRIBUTORS. **Image module**. In: Pillow documentation. [S. l.], [s. d.]. Disponível em: https://pillow.readthedocs.io/en/stable/reference/Image.html. Acesso em: 16 out. 2026.

PYTORCH CONTRIBUTORS. **CrossEntropyLoss**. In: PyTorch documentation. [S. l.], [s. d.]. Disponível em: https://docs.pytorch.org/docs/stable/generated/torch.nn.CrossEntropyLoss.html. Acesso em: 16 out. 2026.

RODOLA, Giampaolo. **psutil documentation**. [S. l.], [s. d.]. Disponível em: https://psutil.readthedocs.io/stable/. Acesso em: 17 out. 2026.

SCIKIT-LEARN DEVELOPERS. **classification_report**. In: Scikit-learn documentation. [S. l.], [s. d.]. Disponível em: https://scikit-learn.org/stable/modules/generated/sklearn.metrics.classification_report.html. Acesso em: 16 out. 2026.

THUNG, Gary; YANG, Mindy. **TrashNet**. GitHub, [2016]. Disponível em: https://github.com/garythung/trashnet. Acesso em: 16 out. 2026.

YANG, Mindy; THUNG, Gary. **Classification of trash for recyclability status**. Stanford: Stanford University, 2016. Relatório de projeto, CS229. Disponível em: https://cs229.stanford.edu/proj2016/report/ThungYang-ClassificationOfTrashForRecyclabilityStatus-report.pdf. Acesso em: 16 out. 2026.